

Task 2 云端真实运行日志

一句话结论

双 A800 环境上的固定 30 样例 Task 2 已以退出状态 0 完成；工程闭环成立，质量瓶颈已从“能否运行”收敛到“实体识别、证据一致性与拒答校准”。

报告人：俞凡

日期：2026-07-16

后端：vLLM 0.7.3

模型：Llama 3.2 11B Vision

数据：validation v0.1.2

结果先行：Task 2 已跑通，质量问题也被看见

30/30

样例与 trace 一致

真实固定样例

0

运行错误

status 全部为 ok

3:14.88

墙钟耗时

含环境初始化

**38,686
MiB**

GPU0 峰值显存

GPU1 保持空闲

完成性证据。正式命令退出状态为 0；run_config.json、manifest、trace、CSV 与分数文件均覆盖同一组 30 条样例。run config 与 manifest 的 source index 顺序一致，trace 按 manifest 顺序记录；CSV 的 query 集合一致，但输出排序不同。远端最终测试为 32/32 通过。

不能包装成“性能提升”。仓库关闭了语义裁判，精确匹配为 0/30；它不是官方 leaderboard 分数。单人快速人工复核仅用于定位问题：核心正确 7、部分覆盖 6、不正确 17，必须在后续双人复核或官方评测后再形成性能结论。

这次中期汇报可以安全地说什么

- 可以说：Task 2 的图像 KG、Web 检索、11B 多模态生成、trace 和结果落盘已形成真实闭环。
- 可以说：29/30 样例同时获得图像与 Web 证据，检索调用无异常；回答质量的主要瓶颈是实体错认而非服务不可用。
- 不应说：当前系统已优于 Vision 或 Task 1；本轮没有完成同清单的成对消融。
- 下一步要证明：VEGA-RAG 的证据一致性门控能否减少实体错认，并在可控延迟下改善真实性。

实验对象与可复现配置

项目	本次真实配置	可复现证据
实例	Ubuntu 22.04.3; 2 张 NVIDIA A800-SXM4-40GB; 32 逻辑 CPU; 62 GiB RAM	environment-check.log、GPU telemetry
运行方式	单 卡 GPU0; 运行期 GPU0 38,686 MiB, GPU1 10 tensor_parallel_size=1; GPU1 不参与该基线	MiB
后端	Python 3.10.20; vLLM 0.7.3; Torch 2.5.1+cu124; Transformers 4.49.0	pip-check-after-pin.log
生成模型	unsloth/Llama-3.2-11B-Vision-Instruct, MIlama 架构, 五个 safetensors 分片	五分片 SHA-256 与公开 LFS OID 一致
检索模型	BAAI BGE large en v1.5; OpenAI CLIP ViT-L/14 336	离线完整 pipeline 验证退出 0
索引数据	image 34,557 条; web 904,899 条 387 条 validation 分片中按 seed 20260712 分层选 30 条	Chroma 实际打开、计数验证五个 domain、五个 query category
图像输入	23 条官方 Wikimedia 1280px 缩略图缓存; 7 条 Parquet 内嵌图像	image_prefetch.json, 失败 0

模型来源说明。官方 Meta 仓库匿名访问返回 401，因此本次使用公开 Unsloth 镜像，并公开记录来源、架构和 LFS 哈希。报告不把该镜像描述为“官方授权权重”。

环境取舍。40GB 单卡足以容纳 19.91 GiB 模型权重、1.85 GiB 激活峰值和 11.78 GiB KV cache；双卡中的第二张卡更适合并行跑成对基线，而不是在当前硬编码单卡设置下空耗。

从输入到答案：真实执行链路



正式命令


```
python scripts/week2_experiment.py \
--mode task2 --backend vllm --num-samples 30 \
--seed 20260712 \
--dataset-path local_data/.../validation-00004-of-00005.parquet \
--output-dir artifacts/week2/real_task2_30
```

一致性门禁

证据对象	manifest	trace	all CSV	score total
真实数量	30	30	30	30
门禁结果	PASS	PASS	PASS	PASS

正式运行内部计时为 173.01 秒；外层墙钟为 194.88 秒。差值来自 Conda 包装、进程创建与收尾。两者均保留，避免只报更好看的数字。


GPU 证据：单卡能跑满，第二张卡可用于成对实验



设备	峰值显存	峰值利用率	峰值功耗	峰值温度
GPU0 A800	38,686 MiB	100%	347.57 W	53°C
GPU1 A800	10 MiB	0%	44.01 W	30°C

不能说“双卡加速了本次 Task 2”。实例能看到两张 A800，但正式命令只暴露 GPU0，vLLM 的 tensor parallel 为 1。GPU1 的正确用途是下一轮同时运行 baseline 与 ablation，保证同清单、同时间窗的成对比较。


延迟结构：生成占主导，检索门控仍有预算



观察	数据	含义
冷启动图像检索	最大 858.0 ms，中位 91.8 ms	首条加载效应明显，后续稳定
Web 检索	中位 43.8 ms，P95 63.5 ms	再做一次轻量一致性判断有可用预算
生成	中位 1,460.1 ms，P95 2,757.4 ms	总延迟主要由生成决定
回答长度	中位 30 token；6 条达到或超过 75 to-ken	截断与跑题需要作为质量 guardrail

trace 的 generation 与 total 延迟以 batch 为单位共享，因此 30 条只有 8 组唯一值。后续 trace v3 应同时记录 batch latency 与 per-sample token throughput，避免把共享耗时误解释为单条独立耗时。

答案质量：双检索可用，但“检索到”不等于“答对”



最大根因不是服务错误，而是实体错认

实体错认	11
部分证据覆盖	6
推理或事实错误	4
跑题或截断	1
不恰当拒答	1
核心正确	7

成功样例。“Fiat 500 设计师在 1959 年获得什么奖？”回答 Compasso d’Oro；“牛肉斯特罗加诺夫起源于哪个世纪？”回答 19 世纪；“Nakagusuku 城堡由谁建造？”回答 Gosamaru。三者与参考核心信息一致。

失败样例。Trithuria inconspicua 被误识别为西澳植物；台湾博物馆被误识别为美国博物馆；Jeep 与 Toyota 4Runner 的基础发动机比较结论相反。29/30 同时有两路证据仍出现 11 个实体错误，说明“多检索”本身不等于“证据一致”。

复核口径：1 名复核者逐条对照 ground truth 与最终回答；只用于错误归因，不替代官方语义裁判或双人一致性标注。

工程排障不是花絮，而是可复现能力

失败点	直接证据	最小修复与验证
Web 索引下载极慢	Hugging Face Xet 并发降为 1，约 0.1 MB/s	映射 LFS OID 后用 aria2 Range 续传；5.2GB 与 3.6GB 两文件 SHA-256 完全匹配
Chroma 变量过多	904,899 条 Web 元数据与 34,557 条图像元数据全量 get 触发 SQLite 限制	改为命中 ID 的惰性元数据访问与缓存；离线真实 pipeline 返回结果，32 项测试覆盖
依赖版本冲突	Transformers 5.14 拒绝 Torch 2.5 加载 CLIP bin	对齐 vLLM 0.7.3 到 Transformers 4.49.0；pip check 为 0 冲突
评测 tokenizer 受限	评测器硬编码 Meta 1B tokenizer，离线时失败	优先复用本地 11B tokenizer，保留上游 fallback；目标测试通过
图像外链超时与 429	默认 Wikimedia 新加坡节点握手超时，原图请求触发 robot policy	指向官方 eqiad IP；使用允许的 1280px 缩略图；规范 UA；23/23 缓存成功
SSH 会话回收	前台冒烟被线路断开连带终止	tmux 守护，日志实时落盘，外层 time 写最终退出状态

汇报价值。每个失败都有“症状、根因、最小修复、自动测试、真实复验”五段证据。这比只展示一个最终数字更能证明个人对实训的工程贡献。

创新主线：VEGA-RAG 让两路证据先对齐，再决定是否回答



为什么不再堆一个检索器？ 当前系统 29/30 已同时获得图像与 Web 证据，却仍有 11 个实体错认。VEGA-RAG 的研究问题是：**当两路证据冲突或实体 margin 过低时，系统能否主动追加检索或拒答，而不是把更多文本直接塞给生成模型？**

门控分数与动作

$$C = \alpha s_{image} + \beta s_{web} + \gamma A_{entity} - \delta D_{conflict}$$

置信区间	动作	可解释 trace
$C \geq \tau_h$	直接回答	使用的 KG/WEB ID、分数、实体一致性
$\tau_l < C < \tau_h$	重写查询并扩大 K	原查询、新查询、追加证据、延迟增量
$C \leq \tau_l$	校准拒答	冲突实体、缺失事实、拒答原因

三条可证伪假设，比“模型更聪明”更像研究

- 1. **实体一致性假设：**以 image top-1/top-2 margin、KG 实体属性与 Web 实体共现构成门控，可降低实体错认样例占比。
- 2. **自适应检索假设：**只在中置信样例扩大 K 或重写查询，能在 P95 延迟增加不超过 20% 的条件下提升正确核心信息覆盖。
- 3. **拒答校准假设：**对低置信或证据冲突样例拒答，可减少“错误但自信”的答案，并提高 truthfulness，而不是追求表面回答率。

A：研究亮点

证据一致性不只是相似度相加；门控动作本身可消融，可解释，可证伪。研究动机直接来自 11 个实体错认。

B：工程亮点

固定 manifest、惰性索引、图像预取、32 项测试、trace ID 和 GPU/延迟证据让每个结论能被重跑。

C：演示亮点

用“绿、黄、红”三张样例卡现场演示：绿卡 Fiat 奖项直接回答；黄卡 Sourdough 追加检索后补齐要点；红卡台湾博物馆实体冲突时拒答。每张卡同时显示实体、两路证据、gate 分数、动作和耗时。

研究依据

CRAG-MM 指出简单 RAG 在 truthfulness 上仍弱，并考虑图像质量、问题类型、实体流行度和信息动态性。Corrective RAG 支持“先评估检索质量，再决定纠正动作”；Self-RAG 支持自适应检索与显式反思。VEGA-RAG 将两者落到多模态实体一致性，而不是声称一个未经验证的新理论。

消融矩阵：同一清单、成对比较、先小后大

编号	版本	一致性门控	自适应 K	校准拒答	要回答的问题
B0	当前 Task 2 baseline	–	–	–	真实基线与错误谱
A1	B0 + entity agreement	有	–	–	实体错认是否下降
A2	A1 + query rewrite	有	有	–	中置信样例是否受益
A3	A1 + abstention	有	–	有	truthfulness 是否改善
FULL	VEGA-RAG	有	有	有	质量、延迟与拒答的整体取舍

评测设计

- **配对样本：**先复用本次 30 条做开发诊断；参数冻结后扩大到更多 validation，禁止只挑展示样例。
- **质量指标：**官方可用时报告 accuracy、missing、hallucination、truthfulness；同时报告双人复核一致率。
- **检索指标：**实体识别准确率、top-2 margin、evidence agreement、Web/KG 冲突率、Recall@K。
- **系统指标：**run completion、P50/P95 latency、GPU 峰值显存、每样例 token 与证据数。
- **统计呈现：**对 30 条成对结果使用 bootstrap 置信区间或 McNemar 检验；小样本只报效应与区间，不只报单点提升。

双 A800 的正确实验方式。 GPU0 跑 B0，GPU1 同时跑 A1/A2；两边使用同 manifest 与 seed。这样老师看到的不只是“我租了两张卡”，而是“我把硬件变成可比较实验的吞吐工具”。

中期 PPT 审查：后三页应从“待云端”升级为“证据到研究”

原页	现有信息	建议替换
第 5 页	19 个测试、120 条合成 trace、30 条真实样本清单；明确暂无 benchmark	改为“32 项远端测试、Task 2 30/30、173.01 秒、GPU 38,686 MiB、退出 0”，保留非官方指标警示
第 6 页	Task 1/Task 2 仍标“待云端”	改为三层证据：运行完成性、检索可用性、单人快速质量复核；用成功与失败各一例
第 7 页	“可运行、可追溯、尚未达到性能验收”与云端 checklist	改为“云端闭环已完成，质量验收刚开始”；引出 VEGA-RAG 与成对消融矩阵

推荐的 7 页讲述顺序

1. 任务与 stakes：多模态问答最难的是“图像实体 + 动态事实 + 真实性”。
2. 三种任务模式：Vision、Image KG、Image KG + Web。
3. 工程底座：固定清单、trace、测试与真实索引。
4. 真实云端结果：30/30 与 GPU/耗时证据。
5. 质量诊断：7 正确、6 部分、17 不正确，实体错认 11。
6. 研究创新：VEGA-RAG 证据一致性门控。
7. 下一步：双 A800 成对消融与可视化 demo。

不要把 exact-match 0 隐藏，也不要将单人快速复核包装成官方 accuracy。最有说服力的表达是：“我们已经有了能暴露错误的真实系统，因此可以提出可证伪的改进。”

明天现场演示：90 秒内让老师看到研究闭环

1. **0-15 秒**：打开正式运行摘要，指出 exit 0、30/30、同一 seed、GPU 峰值与真实日志路径。
2. **15-40 秒**：打开 Fiat 500 成功 trace，依次高亮 KG4、WEB1 与最终 Compasso d'Oro 答案。
3. **40-65 秒**：打开台湾博物馆失败 trace，展示图像实体与 Web 实体冲突；说明 baseline 没有 gate，所以错误继续进入生成。
4. **65-90 秒**：切到 VEGA-RAG 三色门控图，说明下一周用同 30 条成对消融验证，而不是换样本讲故事。

现场必须准备

PDF 本地副本；成功与失败 trace 的静态截图；断网时可演示的 JSON；一页 GPU 曲线；正式命令与 exit 0。

不要现场冒险

不重新下载 21GB 模型；不临时跑完整 30 条；不把云服务器 SSH 当唯一入口；不承诺未完成的 A1/A2 提升。

老师可能追问的三句话回答

- **为什么 exact-match 是 0?** 当前答案多为自然语言扩写，精确字符串匹配过严，同时确有实体和推理错误；所以我们分开报告完成性、人工诊断与未来官方语义分数。
- **创新在哪里?** 不是再加一个搜索源，而是把图像实体、KG 与 Web 的一致性变成显式 gate，并让系统选择回答、追加检索或拒答。
- **如何证明有效?** 同一 manifest 做 B0/A1/A2/A3/FULL 成对消融，报告质量、拒答校准、P95 延迟和显存，不只挑成功案例。

下一周执行清单：从基线到可发表式实验

优先级	工作包	验收门槛
P0	trace v3: 记录 top-2 margin、entity agreement、batch 与 per-sample latency	32 项测试不回归；30 条 trace 字段齐全
P0	双人复核本次 30 条，建立 correct/partial/incorrect 与根因标签	分歧样例有仲裁；报告一致率
P1	实现 A1 entity agreement gate	同清单实体错认数相对 B0 下降
P1	实现 A2 query rewrite 与动态 K	P95 延迟增量受控；中置信样例覆盖改善
P1	实现 A3 calibrated abstention	错误自信回答下降，拒答原因可追踪
P2	双 A800 并行成对实验与 demo viewer	一键重放成功、冲突、拒答三类 trace

决策门。如果 A1 在 30 条上不能明显减少实体错认，就不继续堆多轮 agent；先检查图像实体锚点、相似度 margin 与 KG 元数据质量。只有 A1 成立，才扩展到 A2/A3。

本周的关键进展不是“模型跑出了答案”，而是我们获得了可以复现、可以失败、也可以被改进的真实基线。

附录 A：复现与验证命令

图像预取

```
python scripts/prefetch_week2_images.py \  
--dataset-path local_data/.../validation-00004-of-00005.parquet \  
--manifest artifacts/week2/real_task2_30/sample_manifest.json \  
--output artifacts/week2/real_task2_30/image_prefetch.json
```

正式运行与一致性检查

```
CUDA_VISIBLE_DEVICES=0 \  
CRAG_MODEL=/root/crag-task2-run/models/unsloth-Llama-3.2-11B-Vision-Instruct \  
python scripts/week2_experiment.py --mode task2 --backend vllm \  
--num-samples 30 --seed 20260712 --dataset-path local_data/...parquet \  
--output-dir artifacts/week2/real_task2_30  
python -m unittest discover -s tests -v
```

验收结果

- 正式运行：Exit status 0；外层墙钟 3:14.88；run 内部 173.01 秒。
- 最终远端测试：32/32 OK；pip check：No broken requirements。
- 数据一致性：manifest 30 = trace 30 = all CSV 30 = score total 30；query 集合一致，CSV 输出排序不同。
- 图像输入：cached 23 + embedded 7 = 30；failed 0。

附录 B：证据文件索引与来源

文件	证明内容
artifacts/week2/real_task2_30/run_config.json	mode、backend、模型、seed、30 条索引、内部耗时
.../agent_trace.jsonl	每条 query、Image KG/Web 证据、分数、答案、延迟、错误
.../turn_evaluation_results_all.csv	ground truth、最终回答与本地评测字段
.../manual_review.csv	非官方单人快速复核标签与根因说明
.../image_prefetch.json	23 条缓存、7 条内嵌、0 失败
.../logs/task2-30.log	vLLM 配置、权重/KV cache、正式输出、外层 time、Exit status 0
.../logs/gpu-telemetry.csv	双 A800 的 5 秒采样温度、功耗、显存和利用率
.../logs/remote-unit-tests-final.log	正式环境最终 32 项测试 OK

研究与软件来源

1. CRAG-MM: A Benchmark for Multimodal RAG. [arXiv:2510.26160](#).
2. Corrective Retrieval Augmented Generation. [arXiv:2401.15884](#).
3. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. [arXiv:2310.11511](#).
4. 实训仓库: [JoshuaZ16/intelligent-training-crag-mm](#).
5. 公开模型镜像: [unsloth/Llama-3.2-11B-Vision-Instruct](#).
6. 数据与检索索引: [Hugging Face crag-mm-2025](#), validation revision v0.1.2.

本报告未记录或暴露 SSH 密码、访问 token；所有性能与质量结论均以同步到本地的日志和结果为依据。