

暑期实训中期汇报研究报告

VEGA-RAG

CRAG-MM Task 2 真实多轮性能对比实验

双 A800 成对运行 · 固定 30 样本 · 覆盖率约束校准 · 版本盲化等价类复核

4 正式成对轮次

240 正式模型输出

47 唯一回答类复核

个人负责人：俞凡

2026 年 7 月 16 日

所有结论来自真实落盘结果；未使用伪实验或虚构提升。

执行摘要

一句话结论：覆盖率约束下，校准拒答能够减少错误但自信的回答，却没有提高正确答案数量；FULL 在本次 30 条真实分布中没有触发追加检索，最终与 A3 完全等价。


主评测 20 条	Accuracy	Missing	Hallucination	Truthfulness
B0	30%	0%	70%	-0.40
A1 / A2	30%	5%	65%	-0.35
A3 / FULL	25%	20%	55%	-0.30

可汇报的真实发现

- A1/A2 相比 B0：Accuracy 不变，Hallucination 下降 5 个百分点，Truthfulness 上升 0.05；变化来自模型自发拒答，不是新增正确答案。
- A3/FULL 相比 B0：Hallucination 下降 15 个百分点，Truthfulness 上升 0.10，但 Accuracy 同时下降 5 个百分点。
- A3 的 4 次主评测拒答中，3 次避免了原本的错误回答，1 次拒掉原本正确答案；这正是选择性预测的覆盖率与风险权衡。
- 主评测仅 20 条，McNemar 检验均为 $p = 1.0$ ；所有提升都应表述为趋势，不可宣称统计显著。

1 研究问题与消融结构

本研究不是简单比较不同 Prompt，而是把多模态检索增强生成拆成三个可独立审计的控制点：实体一致性、按需追加检索、校准拒答。



版本	真实动作	本轮要回答的问题
B0	Image KG + Web，各一次搜索	原始基线是否稳定可复现？
A1	按实体分组，结合图像分数、Web 支持和问题属性重排	是否减少错实体？
A2	仅在 $\tau_{low} < s < \tau_{high}$ 时增加一次 Web 搜索	额外证据是否值得成本？
A3	$s \leq \tau_{low}$ 或数值冲突时跳过生成并拒答	是否减少错误但自信回答？
FULL	高置信回答、中置信扩展、低置信/冲突拒答	三个模块组合后能否形成净收益？

2 实验设计与防止结果泄漏

2.1 固定样本与双卡成对运行

- 数据：CRAG-MM single-turn validation 固定 manifest，共 30 条；seed 为 20260712。
- 校准：manifest 前 10 条；主评测：后 20 条；全 30 条仅作为含校准样本的补充结果。
- 模型：同一 Llama-3.2-11B-Vision-Instruct 本地权重；GPU0/GPU1 分别运行同轮基线与变体。
- 每轮启动差均小于 0.002 秒；每侧均为 30 条 trace v3、30 条结果、退出状态 0。
- 四轮 B0 回答达到 30/30 完全一致，说明 temperature=0 的当前管线具备可复现性。

2.2 一个值得汇报的校准失败模式

原始目标按 Truthfulness、Accuracy、较低 Missing 顺序选择阈值。前 10 条真实校准后，无约束最优为 $\tau_{low} = 0.5, \tau_{high} = 0.6$ ，因为 10/10 全部拒答得到 Truthfulness=0，高于当前回答系统的 -0.2。

研究洞察：Truthfulness 本身会奖励“安全但无用”的全拒答策略。因此在查看后 20 条主评测结果之前，预先加入回答覆盖率 $1 - Missing \geq 70\%$ 的可行性约束，再在可行候选中优化原目标。

校准方案	τ_{low}/τ_{high}	覆盖率	Accuracy	Truthfulness
无约束诊断（保留但不采用）	0.5 / 0.6	0%	0%	0.00
覆盖率约束正式冻结	0.2 / 0.3	80%	30%	-0.20


正式阈值文件 SHA-256: fcb0fe48...e45cdbc。15 个网格候选中 12 个满足覆盖率约束，3 个被排除；正式轮开始后阈值未再改变。

3 运行验收与失败证据

轮次	双侧退出	Trace/结果	接受状态	说明
R1 B0 vs A1	0/0	30/30, 30/30	接受	两侧均每样本 2 次搜索
R2 B0 vs A2	0/0	30/30, 30/30	接受	A2 仅 1 条扩展，新增 4 条证据
R3 B0 vs A3	0/0	30/30, 30/30	排除	特殊 token 污染标准拒答字符串
R3b B0 vs A3	0/0	30/30, 30/30	排除	通用归一化覆盖冲突拒答原因
R3c B0 vs A3	0/0	30/30, 30/30	接受	5 次拒答均跳过生成且原因正确
R4 B0 vs FULL	0/0	30/30, 30/30	接受	自然 expand=0，FULL 与 A3 等价

两次 R3 排除不是伪造失败，而是严格验收发现的工程问题。修复均遵循失败测试先行：本地和远端最终为 62/62 单元测试通过；旧目录和日志全部保留，不覆盖结果。

4 主评测 20 条：质量结果



版本	N	C	M	H	Accuracy	Missing	Halluc.	Truth.
b0	20	6	0	14	0.3	0	0.7	-0.4
a1	20	6	1	13	0.3	0.05	0.65	-0.35
a2	20	6	1	13	0.3	0.05	0.65	-0.35
a3	20	5	4	11	0.25	0.2	0.55	-0.3
full	20	5	4	11	0.25	0.2	0.55	-0.3

4.1 统计解释

- A1/A2 的 Accuracy 差为 0; Truthfulness 差为 +0.05, 10,000 次配对 bootstrap 95% CI 为 [0.00, 0.15]。
- A3/FULL 的 Accuracy 差为 -0.05, 95% CI 为 [-0.15, 0.00]; Truthfulness 差为 +0.10, 95% CI 为 [-0.10, 0.30]。
- A1/A2 的正确性 McNemar 无差异对; A3/FULL 仅有 1 个“基线正确、变体非正确”差异对，双侧精确 $p = 1.0$ 。

5 错误转移与拒答质量

主评测中实体错误仍是最大问题：B0 为 7 条，A1/A2 降为 6 条，但没有形成新增正确答案。A3/FULL 的四次拒答产生如下转移：

转移	数量	解释	评价
incorrect → missing	3	阻止错误但自信回答	有益拒答
correct → missing	1	Ardvreck Castle 样本低分但原答案正确	有害拒答
incorrect → incorrect	8	门控未覆盖的大量实体/事实错误	仍需改进
partial → partial	3	证据覆盖不足未被门控改变	仍需改进

拒答精度（主评测）：3/4 拒答避免了幻觉，1/4 错拒正确答案。它说明“冲突检测”比单纯低分更有价值：4 个冲突拒答中有 3 个位于主评测且阻止错误；唯一低置信拒答恰好拒掉正确的建筑比较答案。

5.1 代表性真实样本

案例	真实现象	研究含义
发动机类型	B0 回答 2.7L 直四，参考为 V8；A3 因数 值冲突拒答	冲突门控避免明确错误
建筑寿命	B0 正确回答 Ardvreck Castle 更久；A3 因实体分数 0 拒答	低分不等于错误，需改善置信建模
台湾博物馆 GDP	多版本把台湾误识别成美国	当前瓶颈是视觉实体识别，不是 Web 证据数量
A2 唯一扩展	30 条仅 1 条触发扩展，新增 4 条 Web 证据但语义标签未改善	追加检索的触发覆盖不足且边际收益为零

6 系统成本与 GPU 性能

Run	Wall(s)	P50(ms)	P95(ms)	Search	Ans	Exp	Abs	Mem(MiB)	GPU%
B0-R1	413.3	1,817	5,020	2	30	0	0	38,686	100
A1-R1	400	1,767	5,411	2	30	0	0	38,686	100
B0-R2	335.3	1,164	1,960	2	30	0	0	38,686	100
A2-R2	337.4	1,195	1,949	2.033	29	1	0	38,686	100
B0-R3c	301.8	1,645	4,998	2	30	0	0	38,686	100
A3-R3c	304.7	1,697	5,800	2	25	0	5	38,686	100
B0-R4	306.8	1,683	5,061	2	30	0	0	38,686	100
FULL-R4	313.9	1,741	4,223	2	25	0	5	38,686	100

时延口径：P50/P95 来自 trace 的批处理响应周期；同一 vLLM batch 内样本共享生成时间，不等于严格单请求 latency。Wall time 包含索引与模型加载，P50/P95 不包含加载。所有正式 run 的峰值显存均约 38,686 MiB，GPU 峰值利用率均为 100%。

系统成本没有显示 A2 的显著负担，因为冻结阈值后仅 1/30 扩展，平均搜索调用从 2.000 上升到 2.033。A3/FULL 跳过 5 条生成，但整体 wall time 仍受索引和模型加载主导，因此不能据此宣称显著加速。

7 全 30 条补充结果

该范围包含 10 条校准样本，只用于描述，不作为无偏主结论。

版本	N	C	M	H	Acc.	Miss.	Hall.	Truth.	Cov.
b0	30	6	1	23	0.2	0.033	0.767	-0.567	0.967
a1	30	6	2	22	0.2	0.067	0.733	-0.533	0.933
a2	30	6	2	22	0.2	0.067	0.733	-0.533	0.933
a3	30	5	6	19	0.167	0.2	0.633	-0.467	0.8
full	30	5	6	19	0.167	0.2	0.633	-0.467	0.8

全 30 条趋势与主评测一致：A3/FULL 的 Hallucination 从 0.767 降到 0.633，Truthfulness 从 -0.567 提高到 -0.467，但 Accuracy 从 0.200 降到 0.167。

8 结论、创新点与下一阶段

8.1 可以站得住的创新点

- 覆盖率约束校准：**不是追求单一 Truthfulness 最大，而是先限制系统最低可用覆盖率，避免全拒答退化。
- 响应等价类复核：**150 个版本答案按“同问题、同文本”压缩为 47 类，避免同一答案因版本不同被打出不一致标签，同时保留可逆映射。
- 行为级验收：**不仅看最终分数，还检查搜索次数、gate action、拒答原因、是否真正跳过生成、冻结阈值哈希和失败目录。
- 负结果可解释：**FULL 没有虚构提升。真实结果表明当前主要瓶颈仍是视觉实体识别；仅增加 Web 证据无法修复错实体。

8.2 下一阶段优先级

优先级	方案	验证方式
P0	用独立视觉实体分类置信度替代当前弱一致性分数	检查 Ardvreck 类正确低分是否减少
P1	冲突检测从“数字集合不相交”升级为属性对齐冲突	对发动机、年份、长度分别建立属性槽位
P1	A2 触发器纳入实体 margin 与 Web 支持，而不只看总分区间	提高真正需要补证样本的召回率
P2	扩大到完整 validation 或重复 seed	提升统计功效并验证阈值迁移性

汇报边界：本报告的语义指标来自单人固定量表复核，不是 CRAG-MM 官方 leaderboard 裁判；复核过程使用匿名 response ID，但评审者此前接触过部分运行上下文，因此不宣称严格双盲。所有数值、负结果和失败运行均来自真实文件。

附录：公式与可复核产物

$$\begin{aligned} Accuracy &= \frac{C}{N}, & Missing &= \frac{M}{N}, \\ Hallucination &= \frac{H}{N}, & Truthfulness &= \frac{2C + M}{N} - 1 = Accuracy - Hallucination. \end{aligned}$$

- 冻结阈值与无约束对照：artifacts/week2/vega_real_ablation/calibration/
- 真实正式轮与失败轮：artifacts/week2/vega_real_ablation/round_*
- 复核映射、标签、bootstrap、McNemar、错误转移：artifacts/week2/vega_real_ablation/comparison/
- PDF 图表数据与验收清单：output/pdf/vega_assets/